

MAT-269: Sesión 7

Estimación bajo restricciones sobre μ y Σ

Felipe Osorio

fosorios.mat.utfsm.cl

Departamento de Matemática, UTFSM



Suponga $\mathbf{x}_1, \dots, \mathbf{x}_n$ vectores aleatorios IID desde $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y considere:¹

1. $\boldsymbol{\mu} = \boldsymbol{\mu}_0$ conocido. Entonces,

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}_0)(\mathbf{x}_i - \boldsymbol{\mu}_0)^\top.$$

2. $\boldsymbol{\Sigma} = \boldsymbol{\Sigma}_0$ conocido. De este modo,

$$\hat{\boldsymbol{\mu}} = \bar{\mathbf{x}}.$$

3. $\boldsymbol{\mu} = \gamma \mathbf{a}$, $\gamma \in \mathbb{R}$ con $\mathbf{a} \in \mathbb{R}^p$ conocido. Luego,

$$\hat{\gamma}_{\boldsymbol{\Sigma}} = \frac{\mathbf{a}^\top \boldsymbol{\Sigma}^{-1} \bar{\mathbf{x}}}{\mathbf{a}^\top \boldsymbol{\Sigma}^{-1} \mathbf{a}}.$$

Para $\boldsymbol{\Sigma}$ desconocido, tenemos:

$$\hat{\gamma} = \frac{\mathbf{a}^\top \mathbf{S}^{-1} \bar{\mathbf{x}}}{\mathbf{a}^\top \mathbf{S}^{-1} \mathbf{a}}.$$

¹Ud. lo deberá resolver como parte de la Tarea 1 (Entrega: 4 Mayo).



4. $A\mu = a$, $A \in \mathbb{R}^{q \times p}$, $a \in \mathbb{R}^q$ matrices conocidas. Luego

$$\hat{\mu}_{\Sigma} = \bar{x} - \Sigma A^{\top} (A \Sigma A^{\top})^{-1} (A \bar{x} - a),$$

para Σ desconocido

$$\hat{\mu} = \bar{x} - S A^{\top} (A S A^{\top})^{-1} (A \bar{x} - a).$$

5. $\Sigma = \phi V$ con $V > 0$ conocida y $\phi > 0$. Por tanto,

$$\hat{\mu} = \bar{x}, \quad \hat{\phi} = \frac{1}{p} \text{tr}(V^{-1} S).$$



Matriz de covarianza diagonal

Suponga que

$$\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}, \quad \text{con} \quad \Sigma_{12} = \mathbf{0} = \Sigma_{21}^\top,$$

y $\mu = (\mu_1^\top, \mu_2^\top)^\top$. De este modo, tenemos $\theta = (\mu_1, \mu_2, \Sigma_{11}, \Sigma_{22})$, así la función de log-verosimilitud adopta la forma:

$$\ell(\theta) = -\frac{np}{2} \log 2\pi - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^\top \Sigma^{-1} (\mathbf{x}_i - \mu).$$

Note que el estimador ML para μ no depende de Σ , luego $\hat{\mu} = \bar{x}$. Ahora, usando que

$$|\Sigma| = \begin{vmatrix} \Sigma_{11} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{vmatrix} = |\Sigma_{11}| |\Sigma_{22}|, \quad \Sigma^{-1} = \begin{pmatrix} \Sigma_{11}^{-1} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22}^{-1} \end{pmatrix}.$$



Matriz de covarianza diagonal

Sigue que la parte relevante de $\ell(\boldsymbol{\theta})$ es dada por:

$$\begin{aligned}\ell(\boldsymbol{\theta}) = & -\frac{n}{2} \log |\boldsymbol{\Sigma}_{11}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}_1)^\top \boldsymbol{\Sigma}_{11}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_1) \\ & - \frac{n}{2} \log |\boldsymbol{\Sigma}_{22}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}_2)^\top \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_2)\end{aligned}$$

que puede ser escrita como:

$$\ell(\boldsymbol{\theta}) = \ell_1(\boldsymbol{\theta}_1) + \ell_2(\boldsymbol{\theta}_2),$$

con $\boldsymbol{\theta}_j = (\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_{jj})$, para $j = 1, 2$, y

$$\ell_j(\boldsymbol{\theta}_j) = -\frac{n}{2} \log |\boldsymbol{\Sigma}_{jj}| - \frac{1}{2} \text{tr } \boldsymbol{\Sigma}_{jj}^{-1} \mathbf{Q}_j(\boldsymbol{\mu}_j),$$

donde

$$\mathbf{Q}_j(\boldsymbol{\mu}_j) = \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu}_j)(\mathbf{x}_i - \boldsymbol{\mu}_j)^\top.$$



Matriz de covarianza diagonal

De ahí que, usando el [Resultado 2](#) de la Sesión 6, obtenemos el estimador ML para Σ :

$$\hat{\Sigma} = \begin{pmatrix} \hat{\Sigma}_{11} & \mathbf{0} \\ \mathbf{0} & \hat{\Sigma}_{22} \end{pmatrix},$$

con

$$\hat{\Sigma}_{jj} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}_j)(\mathbf{x}_i - \bar{\mathbf{x}}_j)^\top,$$

para $j = 1, 2$, donde $\bar{\mathbf{x}} = (\bar{\mathbf{x}}_1^\top, \bar{\mathbf{x}}_2^\top)^\top$.



Muestras con parámetros ‘enlazados’

Suponga que la matriz de datos \mathbf{X} es particionada como:

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_k \end{pmatrix},$$

donde las filas de $\mathbf{X}_i \in \mathbb{R}^{n_i \times p}$ son IID $N_p(\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_{ii})$, para $i = 1, \dots, k$.

Las restricciones más comunes son:

(a) $\boldsymbol{\Sigma}_{11} = \dots = \boldsymbol{\Sigma}_{kk}$ (digamos, $= \boldsymbol{\Sigma}$).

(b) $\boldsymbol{\Sigma}_{11} = \dots = \boldsymbol{\Sigma}_{kk}$ y $\boldsymbol{\mu}_1 = \dots = \boldsymbol{\mu}_k$.



Muestras con parámetros ‘enlazados’

Para el caso en (a) note que podemos escribir:

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^k \ell_i(\boldsymbol{\theta}),$$

donde

$$\ell_i(\boldsymbol{\theta}) = -\frac{n_i}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \text{tr } \boldsymbol{\Sigma}^{-1} \{ \mathbf{Q}_i + n_i (\bar{\mathbf{x}}_i - \boldsymbol{\mu}_i)(\bar{\mathbf{x}}_i - \boldsymbol{\mu}_i)^\top \},$$

Sea

$$\mathbf{S}_i = \frac{1}{n_i} \mathbf{Q}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} (\mathbf{x}_j - \bar{\mathbf{x}}_i)(\mathbf{x}_j - \bar{\mathbf{x}}_i)^\top,$$

para $i = 1, \dots, k$. Es decir,

$$\ell(\boldsymbol{\theta}) = -\frac{1}{2} \sum_{i=1}^k \left\{ n_i \log |\boldsymbol{\Sigma}| + n_i \text{tr } \boldsymbol{\Sigma}^{-1} (\mathbf{S}_i + (\bar{\mathbf{x}}_i - \boldsymbol{\mu}_i)(\bar{\mathbf{x}}_i - \boldsymbol{\mu}_i)^\top) \right\}.$$



Muestras con parámetros ‘enlazados’

Como **no existe** restricciones sobre μ sigue que el MLE de μ es \bar{x}_i ($i = 1, \dots, k$). Además, considere

$$\mathbf{W} = \sum_{i=1}^k n_i \mathbf{S}_i, \quad n = \sum_{i=1}^k n_i.$$

De este modo, la **log-verosimilitud perfilada**, es dada por:

$$\ell_*(\Sigma) = \ell(\hat{\mu}, \Sigma) = -\frac{n}{2} \log |\Sigma| - \frac{1}{2} \text{tr } \Sigma^{-1} \mathbf{W}.$$

De ahí que el MLE para Σ adopta la forma:²

$$\hat{\Sigma} = \frac{1}{n} \mathbf{W} = \frac{1}{n} \sum_{i=1}^k n_i \mathbf{S}_i$$

El caso en (b) es análogo (se deja como Ejercicio).

²Es decir $\hat{\Sigma}_{ii} = \hat{\Sigma}$, para $i = 1, \dots, k$.



MAT-269: Sesión 7

Estimación ML bajo distribuciones de contornos elípticos

Felipe Osorio

`fosorios.mat.utfsm.cl`

Departamento de Matemática, UTFSM



Distribuciones de contornos elípticos

Sabemos que un vector aleatorio p -variado tiene distribución en la familia de contornos elípticos con parámetros $\boldsymbol{\mu} \in \mathbb{R}^p$ y $\boldsymbol{\Sigma} \geq 0$ si su función característica es de la forma:

$$\varphi_{\boldsymbol{x}}(\boldsymbol{t}) = \exp(i\boldsymbol{t}^\top \boldsymbol{\mu}) \phi(\boldsymbol{t}^\top \boldsymbol{\Sigma} \boldsymbol{t}),$$

mientras que si $\boldsymbol{\Sigma} > 0$ el vector aleatorio \boldsymbol{x} tendrá densidad

$$f(\boldsymbol{x}) = |\boldsymbol{\Sigma}|^{-1/2} g[(\boldsymbol{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu})], \quad (1)$$

con $g : \mathbb{R} \rightarrow [0, \infty)$ llamada función generadora de densidad,¹ tal que:

$$\int_0^\infty u^{p/2} g(u) du < \infty.$$

Cuando un vector aleatorio tiene densidad como en (1) anotamos $\boldsymbol{x} \sim \text{EC}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}; g)$.

¹Por ejemplo, $g(u) = (2\pi)^{-p/2} \exp(-u/2)$ para el caso normal.



Distribuciones de contornos elípticos

- **Normal:** $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, con

$$g(u) = c_1 \exp(-u/2).$$

- **t-Student:** $\mathbf{x} \sim t_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}, \nu)$, donde

$$g(u) = c_2(1 + u/\nu)^{-(\nu+p)/2}, \quad \nu > 0.$$

- **Normal contaminada:** $\mathbf{x} \sim CN_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}, \epsilon, \gamma)$, con $\epsilon \in [0, 1)$ y $\gamma > 0$,

$$g(u) = c_1 \{(1 - \epsilon) \exp(-u/2) + \epsilon \gamma^{-p/2} \exp(-u/(2\gamma))\}.$$

- **Cauchy:** $\mathbf{x} \sim \text{Cauchy}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, con

$$g(u) = c_3(1 + u)^{-(p+1)/2}.$$

- **Logística:** $\mathbf{x} \sim L_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, con

$$g(u) = c_4 \exp(-u) / \{1 + \exp(-u)\}^2.$$

- **Exponencial Potencia:** $\mathbf{x} \sim PE_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}, \lambda)$, donde

$$g(u) = c_5 \exp(-u^\lambda/2), \quad \lambda > 0.$$



Observación:

Debemos resaltar que **diferentemente** al caso de la distribución normal, en el caso general de la familia elíptica, podemos tener los siguientes enfoques:

- (a) **Modelo dependiente:** Supondremos $\mathbf{x}_1, \dots, \mathbf{x}_n$ tal que su **densidad conjunta** $\mathbf{x} = (\mathbf{x}_1^\top, \dots, \mathbf{x}_n^\top)^\top$, sigue una distribución de contornos elípticos.
- (b) **Modelo independiente:** Considere $\mathbf{x}_1, \dots, \mathbf{x}_n$ vectores aleatorios **independientes** cada uno con distribución $EC_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}; g)$.



Estimación ML: caso dependiente

Considere la matriz de datos:

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{pmatrix}$$

distribuido de acuerdo con una distribución en la familia de contornos elípticos con parámetros

$$\boldsymbol{\mu} = (\boldsymbol{\mu}_1^\top, \dots, \boldsymbol{\mu}_n^\top)^\top, \quad \boldsymbol{\Sigma} = \text{block diag}(\boldsymbol{\Sigma}_1, \dots, \boldsymbol{\Sigma}_n),$$

donde $\boldsymbol{\Sigma}_j > \mathbf{0}$, para $j = 1, \dots, n$. De este modo, \mathbf{X} tiene densidad de la forma:

$$\prod_{j=1}^n |\boldsymbol{\Sigma}_j|^{-1/2} g \left[\sum_{i=1}^n (\mathbf{x}_j - \boldsymbol{\mu}_j)^\top \boldsymbol{\Sigma}_j^{-1} (\mathbf{x}_j - \boldsymbol{\mu}_j) \right]. \quad (2)$$

Observación:

Evidentemente la distribución matricial en (2) puede ser escrita como una **distribución multivariada** definiendo:

$$\mathbf{x} = \text{vec}(\mathbf{X}^\top) = (\mathbf{x}_1^\top, \dots, \mathbf{x}_n^\top)^\top,$$

de este modo, $\mathbf{x} \sim \text{EC}_N(\boldsymbol{\mu}, \boldsymbol{\Sigma}; g)$, con $N = np$.



Resultado 1 (Anderson, Fang y Hsu, 1986)²

Sea Ω un conjunto en el espacio paramétrico de $(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\boldsymbol{\Sigma} > \mathbf{0}$ tal que si $(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \in \Omega$, entonces $(\boldsymbol{\mu}, c\boldsymbol{\Sigma}) \in \Omega$ para todo $c > 0$. Suponga que g es función tal que $g(\|x\|^2)$ es una densidad en \mathbb{R}^N y $u^{N/2}g(u)$ tiene un **máximo finito** (positivo) u_g . Suponga que, **basado en una** (única) **observación** x desde

$$|\boldsymbol{\Sigma}|^{-1/2}g[(x - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(x - \boldsymbol{\mu})],$$

los MLE bajo normalidad $(\tilde{\boldsymbol{\mu}}, \tilde{\boldsymbol{\Sigma}}) \in \Omega$ existen y son únicos y que $\tilde{\boldsymbol{\Sigma}} > \mathbf{0}$ con prob. 1. Entonces los MLE para $x \sim EC_N(\boldsymbol{\mu}, \boldsymbol{\Sigma}; g)$ son:

$$\hat{\boldsymbol{\mu}} = \tilde{\boldsymbol{\mu}}, \quad \hat{\boldsymbol{\Sigma}} = \frac{N}{u_g} \tilde{\boldsymbol{\Sigma}},$$

y el máximo de la verosimilitud es

$$|\hat{\boldsymbol{\Sigma}}|^{-1/2}g(u_g).$$

²The Canadian Journal of Statistics **14**, 55-59.



Demostración:

Sea $B = |\Sigma|^{-1/N} \Sigma$ y

$$u = (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) = \frac{(\mathbf{x} - \boldsymbol{\mu})^\top B^{-1} (\mathbf{x} - \boldsymbol{\mu})}{|\Sigma|^{1/N}}.$$

Entonces $(\boldsymbol{\mu}, B) \in \Omega$ y $|B| = 1$. Note que

$$\begin{aligned} u^{N/2} &= \left\{ \frac{(\mathbf{x} - \boldsymbol{\mu})^\top B^{-1} (\mathbf{x} - \boldsymbol{\mu})}{|\Sigma|^{1/N}} \right\}^{N/2} \\ &= |\Sigma|^{-1/2} \{(\mathbf{x} - \boldsymbol{\mu})^\top B^{-1} (\mathbf{x} - \boldsymbol{\mu})\}^{N/2}. \end{aligned} \tag{3}$$

De este modo, la función de verosimilitud es dada por:

$$L(\boldsymbol{\theta}) = \{(\mathbf{x} - \boldsymbol{\mu})^\top B^{-1} (\mathbf{x} - \boldsymbol{\mu})\}^{N/2} u^{N/2} g(u). \tag{4}$$



Bajo normalidad, tenemos que

$$g(u) = (2\pi)^{-N/2} \exp(-u/2),$$

y el máximo de (4) es alcanzado en

$$\boldsymbol{\mu} = \tilde{\boldsymbol{\mu}}, \quad \boldsymbol{B} = \tilde{\boldsymbol{B}} = |\tilde{\boldsymbol{\Sigma}}|^{-1/N} \tilde{\boldsymbol{\Sigma}},$$

y $\tilde{u} = N$. En general, el máximo de $L(\boldsymbol{\theta})$ es alcanzado en

$$\hat{\boldsymbol{\mu}} = \tilde{\boldsymbol{\mu}}, \quad \hat{\boldsymbol{B}} = \tilde{\boldsymbol{B}}, \quad \hat{u} = u_g.$$

Entonces,

$$\hat{\boldsymbol{\Sigma}} = |\hat{\boldsymbol{\Sigma}}|^{1/N} \hat{\boldsymbol{B}} = \frac{|\hat{\boldsymbol{\Sigma}}|^{1/N}}{|\tilde{\boldsymbol{\Sigma}}|^{1/N}} \tilde{\boldsymbol{\Sigma}}.$$



Usando (3), sigue que:

$$\frac{|\hat{\Sigma}|^{1/N}}{|\tilde{\Sigma}|^{1/N}} = \frac{(\mathbf{x} - \hat{\mu})^\top \hat{\mathbf{B}}^{-1} (\mathbf{x} - \hat{\mu}) / \hat{u}}{(\mathbf{x} - \tilde{\mu})^\top \tilde{\mathbf{B}}^{-1} (\mathbf{x} - \tilde{\mu}) / \tilde{u}} = \frac{\tilde{u}}{\hat{u}},$$

lo que permite obtener:

$$\hat{\Sigma} = \frac{N}{\hat{u}} \tilde{\Sigma}.$$

Ahora, por (3), tenemos que

$$\begin{aligned} L(\hat{\theta}) &= \{(\mathbf{x} - \hat{\mu})^\top \hat{\mathbf{B}}^{-1} (\mathbf{x} - \hat{\mu})\}^{-N/2} \hat{u}^{N/2} g(\hat{u}) \\ &= \{\hat{u} |\hat{\Sigma}|^{1/N}\}^{-N/2} \hat{u}^{N/2} g(\hat{u}) \\ &= |\hat{\Sigma}|^{-1/2} g(\hat{u}), \end{aligned}$$

lo que concluye la prueba.



Observación:

Si g es continua y diferenciable, entonces u_g ³ es la solución de:

$$g'(u) + \frac{N}{2u}g(u) = 0,$$

o bien

$$\frac{N}{2u} + W_g(u) = 0,$$

donde $W_g(u) = d \log g(u) / du = g'(u)/g(u)$.

Es fácil notar que para las **distribuciones normal** y **t de Student**, $u_g = N$. Para otras distribuciones, u_g debe ser obtenido **numéricamente**. Por ejemplo, para la **distribución logística** se debe resolver:

$$\frac{N}{2u} = \tanh\left(\frac{u}{2}\right).$$

³ u_g maximiza la función $h(u) = u^{N/2}g(u)$.



Ejemplo:

Suponga la densidad conjunta en (2) con $\mu_1 = \dots = \mu_n = \mu$ y $\Sigma_1 = \dots = \Sigma_n = \Sigma$ y $n > p$. Bajo normalidad los MLE de μ y Σ son $\tilde{\mu} = \bar{x}$ y $\tilde{\Sigma} = Q/n$, donde

$$\bar{x} = \frac{1}{n} \sum_{j=1}^n x_j, \quad Q = \sum_{j=1}^n (x_j - \bar{x})(x_j - \bar{x})^\top.$$

De este modo los MLE bajo el modelo elíptico dependiente son:

$$\hat{\mu} = \bar{x}, \quad \hat{\Sigma} = \frac{p}{u_g} Q.$$

