

1. (25 pts) Sea U_1 y U_2 dos variables aleatorias independientes $U(0, 1)$. Suponga $\mathbf{X} = (X_1, X_2, X_3, X_4)^\top$ donde

$$X_1 = U_1, \quad X_2 = U_2, \quad X_3 = U_1 + U_2, \quad X_4 = U_1 - U_2.$$

Calcule la matrix de correlación \mathbf{R} de \mathbf{X} . ¿Cuántas componentes (PC) son de interés? Muestre que

$$\mathbf{t}_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{t}_2 = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \\ 0 \\ 1 \end{pmatrix},$$

son vectores propios de \mathbf{R} asociados a λ 's no triviales. Interprete las dos primeras PC obtenidas.

Solución:

Notemos que $E(X_1) = E(U_1) = 1/2$, $E(X_2) = E(U_2) = 1/2$, $E(X_3) = E(U_1 + U_2) = 1$, $E(X_4) = E(U_1 - U_2) = 0$. Como U_1, U_2 son independientes eso implica que $Cov(U_1, U_2) = 0$, además se tiene que la varianza separa la suma, por ende $Var(X_1) = 1/12$, $Var(X_2) = 1/12$, $Var(X_3) = Var(U_1 + U_2) = Var(U_1) + Var(U_2) = 1/6$, $Var(X_4) = Var(U_1 - U_2) = Var(U_1) + Var(U_2) = 1/6$.

Objetivo: Encontrar la matriz de correlación.

Notemos que \mathbf{X} normalizado viene dado por:

$$\bar{X}_1 = (X_1 - 1/2)/(1/12)^{(1/2)} = (U_1 - 1/2)\sqrt{12}$$

$$\bar{X}_2 = X_2$$

$$\bar{X}_3 = (X_3 - 1)/(1/6)^{(1/2)} = (U_1 + U_2 - 1)\sqrt{6}$$

$$\bar{X}_4 = X_4/(1/6)^{(1/2)} = (U_1 - U_2)\sqrt{6}$$

Por contrucción todas las variables anteriores tienen varianza 1, luego resta calcular los restos de la terminos de la matriz de correlación.

$$Cov(\bar{X}_1, \bar{X}_2) = 0, \text{ pues } U_1, U_2 \text{ son independientes.}$$

$$Cov(\bar{X}_1, \bar{X}_3) = \sqrt{12 \cdot 6} Cov(U_1 - 1/2, U_1 + U_2 - 1) = \sqrt{12 \cdot 6} Var(U_1) = 1/\sqrt{2}$$

$$Cov(X_1, X_4) = 1/\sqrt{2}$$

$$Cov(X_2, X_3) = \sqrt{12 \cdot 6} Var(U_2) = 1/\sqrt{2}$$

$$Cov(X_2, X_4) = \sqrt{12 \cdot 6} (-1) Var(U_2) = -1/\sqrt{2}$$

$$Cov(X_3, X_4) = 6(Var(U_1) - Var(U_2)) = 0$$

De esa forma:

$$\mathbf{R} = \begin{pmatrix} 1 & 0 & 1/2 & 1/\sqrt{2} \\ 0 & 1 & 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} & 1 & 0 \\ 1/\sqrt{2} & -1/\sqrt{2} & 0 & 1 \end{pmatrix}$$

Computacionalmente se tiene que

$$(\lambda_1, \lambda_2, \lambda_3, \lambda_4) = (2, 2, 0, 0)$$

$$\mathbf{T} = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} & -1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} & 1/\sqrt{2} & -1/\sqrt{2} \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{pmatrix}$$

Por tanto las componentes principales son dadas por

$$y_1 = \mathbf{t}_1 \cdot \bar{\mathbf{x}} = \frac{1}{\sqrt{2}} \bar{x}_1 + \frac{1}{\sqrt{2}} \bar{x}_2 + \bar{x}_3$$

$$y_2 = \mathbf{t}_2 \cdot \bar{\mathbf{x}} = \frac{1}{\sqrt{2}} \bar{x}_1 + \frac{1}{\sqrt{2}} \bar{x}_2 + \bar{x}_4$$

$$y_3 = \mathbf{t}_3 \cdot \bar{\mathbf{x}} = -\frac{1}{\sqrt{2}} \bar{x}_1 + \frac{1}{\sqrt{2}} \bar{x}_2 + \bar{x}_4$$

$$y_4 = \mathbf{t}_4 \cdot \bar{\mathbf{x}} = -\frac{1}{\sqrt{2}} \bar{x}_1 - \frac{1}{\sqrt{2}} \bar{x}_2 + \bar{x}_3$$

Como la traza de \mathbf{R} es 4 entonces tenemos que el porcentaje que explica la primera y segunda componente es de un 50% (2/4) mientras que las otras 2 no explican (0/4 = 0).

2. (25 pts) Considere un modelo de análisis factorial

$$\mathbf{x}_i = \boldsymbol{\mu} + \boldsymbol{\Gamma} \mathbf{z}_i + \boldsymbol{\epsilon}_i, \quad i = 1, \dots, n,$$

donde $\boldsymbol{\mu} \in \mathbb{R}^p$, $\mathbf{z}_i \sim N_q(\mathbf{0}, \mathbf{I})$, $\boldsymbol{\epsilon}_i \sim N_p(\mathbf{0}, \boldsymbol{\Psi})$, y $\boldsymbol{\Psi} = \text{diag}(\psi_1, \dots, \psi_p)$. Sea $\widehat{\boldsymbol{\Sigma}} = \widehat{\boldsymbol{\Gamma}} \widehat{\boldsymbol{\Gamma}}^\top + \widehat{\boldsymbol{\Psi}}$, con $\widehat{\boldsymbol{\Gamma}}$ y $\widehat{\boldsymbol{\Psi}}$ los MLE de $\boldsymbol{\Gamma}$ y $\boldsymbol{\Psi}$, respectivamente. Muestre que $\text{tr}(\mathbf{S} \widehat{\boldsymbol{\Sigma}}^{-1}) = p$.

Recuerde que: por el Teorema de Sherman-Morrison-Woodbury, tenemos

$$(\mathbf{A} + \mathbf{BCD})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{B} (\mathbf{C}^{-1} + \mathbf{DA}^{-1} \mathbf{B})^{-1} \mathbf{DA}^{-1}$$

Solución:

Consideremos: $\mathbf{A} = \boldsymbol{\Psi}$, $\mathbf{B} = \boldsymbol{\Gamma}$, $\mathbf{C} = \mathbf{I}_d$ y $\mathbf{D} = \boldsymbol{\Gamma}^\top$.

Por el Teorema de Sherman-Morrison-Woodbury se tiene que:

$$\begin{aligned} \boldsymbol{\Sigma}^{-1} &= (\boldsymbol{\Psi} + \boldsymbol{\Gamma} \boldsymbol{\Gamma}^\top)^{-1} \\ &= \boldsymbol{\Psi}^{-1} - \boldsymbol{\Psi}^{-1} \boldsymbol{\Gamma} (\mathbf{I}_d + \boldsymbol{\Gamma}^\top \boldsymbol{\Psi}^{-1} \boldsymbol{\Gamma})^{-1} \boldsymbol{\Gamma}^\top \boldsymbol{\Psi}^{-1} \end{aligned}$$

Por invarianza de los estimadores tenemos que:

$$\widehat{\boldsymbol{\Sigma}}^{-1} = \widehat{\boldsymbol{\Psi}}^{-1} - \widehat{\boldsymbol{\Psi}}^{-1} \widehat{\boldsymbol{\Gamma}} (\mathbf{I}_d + \widehat{\boldsymbol{\Gamma}}^\top \widehat{\boldsymbol{\Psi}}^{-1} \widehat{\boldsymbol{\Gamma}})^{-1} \widehat{\boldsymbol{\Gamma}}^\top \widehat{\boldsymbol{\Psi}}^{-1}$$

Por resultado visto en clases sabemos que los MLE presentados cumplen las siguientes igualdades

$$\begin{aligned} \mathbf{S} \widehat{\boldsymbol{\Psi}}^{-1} \widehat{\boldsymbol{\Gamma}} &= \widehat{\boldsymbol{\Gamma}} (\mathbf{I}_d + \widehat{\boldsymbol{\Gamma}}^\top \widehat{\boldsymbol{\Psi}}^{-1} \widehat{\boldsymbol{\Gamma}}) \\ \widehat{\boldsymbol{\Psi}} &= \text{diag}(\mathbf{S} - \widehat{\boldsymbol{\Gamma}} \widehat{\boldsymbol{\Gamma}}^\top) \\ \widehat{\boldsymbol{\Lambda}} &= \widehat{\boldsymbol{\Gamma}}^\top \widehat{\boldsymbol{\Psi}}^{-1} \widehat{\boldsymbol{\Gamma}} \end{aligned}$$

Reemplazando se tiene que:

$$\begin{aligned} \mathbf{S} \widehat{\boldsymbol{\Sigma}}^{-1} &= \mathbf{S} \widehat{\boldsymbol{\Psi}}^{-1} - \underbrace{\mathbf{S} \widehat{\boldsymbol{\Psi}}^{-1} \widehat{\boldsymbol{\Gamma}} (\mathbf{I}_d + \widehat{\boldsymbol{\Gamma}}^\top \widehat{\boldsymbol{\Psi}}^{-1} \widehat{\boldsymbol{\Gamma}})^{-1} \widehat{\boldsymbol{\Gamma}}^\top \widehat{\boldsymbol{\Psi}}^{-1}}_{\mathbf{I}_d} \\ &= \mathbf{S} \widehat{\boldsymbol{\Psi}}^{-1} - \widehat{\boldsymbol{\Gamma}} \widehat{\boldsymbol{\Gamma}}^\top \widehat{\boldsymbol{\Psi}}^{-1} \\ &= (\mathbf{S} - \widehat{\boldsymbol{\Gamma}} \widehat{\boldsymbol{\Gamma}}^\top) \widehat{\boldsymbol{\Psi}}^{-1} \end{aligned}$$

Recordemos que:

* $\mathbf{AB} = \text{diag}(\mathbf{A})\mathbf{B}$, si \mathbf{B} es diagonal.

* $\text{Tr}(\mathbf{A}) = \text{Tr}(\text{diag}(\mathbf{A}))$

Finalmente:

$$\begin{aligned} \text{Tr}(\mathbf{S} \widehat{\boldsymbol{\Sigma}}^{-1}) &= \text{Tr} \{ (\mathbf{S} - \widehat{\boldsymbol{\Gamma}} \widehat{\boldsymbol{\Gamma}}^\top) \widehat{\boldsymbol{\Psi}}^{-1} \} \\ &= \text{Tr} \{ \text{diag}(\mathbf{S} - \widehat{\boldsymbol{\Gamma}} \widehat{\boldsymbol{\Gamma}}^\top) \widehat{\boldsymbol{\Psi}}^{-1} \} \\ &= \text{Tr} \{ \widehat{\boldsymbol{\Psi}} \widehat{\boldsymbol{\Psi}}^{-1} \} \\ &= \text{Tr} \{ \mathbf{I}_{p \times p} \} \\ &= p \end{aligned}$$

3. (25 pts) Sea $\mathbf{Y} = \mathbf{X}\mathbf{B} + \mathbf{E}$, donde \mathbf{X} es $n \times k$ de rango k , y las filas de \mathbf{E} son IID $N_p(\mathbf{0}, \Sigma)$. Sea $\mathbf{X}\mathbf{B} = \mathbf{X}_1\mathbf{B}_1 + \mathbf{X}_2\mathbf{B}_2$, donde \mathbf{X}_2 es $n \times k_2$. Derive el test de razón de verosimilitudes para probar $H_0 : \mathbf{B}_2 = \mathbf{0}$

Por construcción se tiene que la \mathbf{Y} sigue la ley normal multivariada con la siguiente estructura:

$$\mathbf{T} \sim N_{n,p}(\mathbf{X}_1\mathbf{B}_1 + \mathbf{X}_1\mathbf{B}_2, \mathbf{I}_n \otimes \Sigma)$$

con densidad conjunta dada por la siguiente ecuación:

$$(2\pi)^{-\frac{np}{2}} |\Sigma|^{-\frac{n}{2}} \exp\left(-\frac{1}{2}\text{Tr}(\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)^\top \Sigma^{-1} (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)\right)$$

Por tanto la log verosimilitud viene dada por:

$$\ell(\mathbf{B}_1, \mathbf{B}_2, \Sigma) = -\frac{np}{2} \ln(2\pi) - \frac{n}{2} \ln|\Sigma| - \frac{1}{2} \text{Tr}\left(\Sigma^{-1} (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)(\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)^\top\right)$$

En primer lugar trabajaremos en encontrar el estimador bajo H_0 es directo pues se tiene un modelo de regresión. Por ende

$$\begin{aligned} \hat{\mathbf{B}}_1 &= (\mathbf{X}_1^\top \mathbf{X}_1)^{-1} \mathbf{X}_1^\top \mathbf{y} \\ \hat{\Sigma} &= \frac{1}{n} (\mathbf{Y} - \mathbf{X}_1\hat{\mathbf{B}}_1)^\top (\mathbf{Y} - \mathbf{X}_1\hat{\mathbf{B}}_1) \end{aligned} \tag{1}$$

Luego para H_1 debemos estimar sin restricciones. Note que:

$$\text{d}_{\mathbf{B}_1} \ell = -\frac{1}{2} \text{Tr}\left(\Sigma^{-1} \left[(-\mathbf{X}_1 \text{d}\mathbf{B}_1)^\top (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2) - (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)^\top (\mathbf{X}_1 \text{d}\mathbf{B}_1)\right]\right) = \text{Tr}\left(\Sigma^{-1} (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)^\top \mathbf{X}_1 \text{d}\mathbf{B}_1\right)$$

Resolviendo $\text{d}_{\mathbf{B}_1} \ell = 0$ entonces:

$$\begin{aligned} \mathbf{X}_1^\top (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2) &= 0 \implies \mathbf{X}_1^\top \mathbf{X}_1\mathbf{B}_1 = \mathbf{X}_1^\top \mathbf{Y} - \mathbf{X}_1^\top \mathbf{X}_2\mathbf{B}_2 \\ \implies \mathbf{B}_1 &= (\mathbf{X}_1^\top \mathbf{X}_1)^{-1} (\mathbf{X}_1^\top \mathbf{Y} - \mathbf{X}_1^\top \mathbf{X}_2\mathbf{B}_2) \end{aligned}$$

Es fácil darse cuenta que con el mismo procedimiento se puede obtener que $\mathbf{B}_2 = (\mathbf{X}_2^\top \mathbf{X}_2)^{-1} (\mathbf{X}_2^\top \mathbf{Y} - \mathbf{X}_2^\top \mathbf{X}_1\mathbf{B}_1)$, y desde la Tarea 1 o visto en clases se puede sacar rápidamente que $\Sigma = \frac{1}{n} (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)^\top (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)$. Con lo que se obtiene un sistema de ecuaciones no lineal de estimación.

$$\begin{pmatrix} \tilde{\mathbf{B}}_1 \\ \tilde{\mathbf{B}}_2 \\ \tilde{\Sigma} \end{pmatrix} = \begin{pmatrix} (\mathbf{X}_1^\top \mathbf{X}_1)^{-1} (\mathbf{X}_1^\top \mathbf{Y} - \mathbf{X}_1^\top \mathbf{X}_2\tilde{\mathbf{B}}_2) \\ (\mathbf{X}_2^\top \mathbf{X}_2)^{-1} (\mathbf{X}_2^\top \mathbf{Y} - \mathbf{X}_2^\top \mathbf{X}_1\tilde{\mathbf{B}}_1) \\ \frac{1}{n} (\mathbf{Y} - \mathbf{X}_1\tilde{\mathbf{B}}_1 - \mathbf{X}_2\tilde{\mathbf{B}}_2)^\top (\mathbf{Y} - \mathbf{X}_1\tilde{\mathbf{B}}_1 - \mathbf{X}_2\tilde{\mathbf{B}}_2) \end{pmatrix}$$

Que se puede resolver numéricamente. Por simplicidad uno puede definir la función matricial $Q(\mathbf{B}_1, \mathbf{B}_2) = (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)^\top (\mathbf{Y} - \mathbf{X}_1\mathbf{B}_1 - \mathbf{X}_2\mathbf{B}_2)$ y así darse cuenta de varias cosas, por ejemplo:

$$\begin{aligned} \text{máx} L(\mathbf{B}_1, \mathbf{B}_2, \Sigma) &= L(\tilde{\mathbf{B}}_1, \tilde{\mathbf{B}}_2, \tilde{\Sigma}) \\ &= (2\pi)^{-\frac{np}{2}} |\tilde{\Sigma}| \exp\left(-\frac{1}{2} \text{Tr}\left(\left[\frac{1}{n} Q(\tilde{\mathbf{B}}_1, \tilde{\mathbf{B}}_2)\right]^{-1} Q(\tilde{\mathbf{B}}_1, \tilde{\mathbf{B}}_2)\right)\right) \\ &= (2\pi)^{-\frac{np}{2}} |\tilde{\Sigma}| \exp\left(-\frac{np}{2}\right) \end{aligned}$$

Y bajo H_0 la verosimilitud toma la forma:

$$\begin{aligned} \text{máx} L(\mathbf{B}_1, \mathbf{0}, \Sigma) &= L(\hat{\mathbf{B}}_1, \mathbf{0}, \hat{\Sigma}) \\ &= (2\pi)^{-\frac{np}{2}} |\hat{\Sigma}| \exp\left(-\frac{np}{2}\right) \end{aligned}$$

Por tanto:

$$\Lambda = \frac{\text{máx} L(\mathbf{B}_1, \mathbf{B}_2, \Sigma)}{\text{máx} L(\mathbf{B}_1, \mathbf{0}, \Sigma)} = \left\{ \frac{|\tilde{\Sigma}|}{|\hat{\Sigma}|} \right\}^{\frac{-n}{2}}$$

Conclusión:

$$LR = \frac{|\tilde{\Sigma}|}{|\hat{\Sigma}|}$$

Y como criterio de rechazo es para p-valores (LR) pequeños.